

在時間序列比對中使用動態時間規整 (DTW) 演算法來判斷序列是否正常時，確定適當的閾值確實是個挑戰。目前使用的方法包括 Median + 6*MAD 以及基於蒙地卡羅模擬的方法。以下是一些可能的改進建議和方法來幫助更準確地確定 DTW 的閾值：

1. 利用基於統計的閾值設置

- 平均絕對誤差 (Mean Absolute Error, MAE): 考慮用平均絕對誤差來計算正常樣態與虛擬序列之間的差異，並將其作為閾值的基礎。
- 常態分佈假設: 如果你的正常樣態與噪音的結合可以近似為常態分佈，可以根據所選定的置信區間來設定閾值。例如，設置為 $\mu + k\sigma$ (其中 μ 為平均值， σ 為標準差， k 為決定閾值寬鬆程度的參數)。

2. 改進蒙地卡羅模擬

- 增加模擬次數: 增加蒙地卡羅模擬的次數可以提高閾值的穩定性和準確性。
- 多種噪音模型: 嘗試不同的噪音模型來生成虛擬序列，然後統合這些結果來決定閾值。這樣可以增加對不同類型噪音的適應性。

3. 使用機器學習模型

- 監督式學習: 使用歷史數據訓練監督式機器學習模型，學習哪些 DTW 距離對應於正常和異常情況。可以考慮使用支持向量機 (SVM)、隨機森林 (Random Forest) 或神經網絡來分類。
- 無監督學習: 應用無監督學習方法，例如聚類 (如 K-means 或 DBSCAN)，找出正常和異常模式之間的自然邊界。

4. 多尺度 DTW (MS-DTW)

- 多尺度分析: 使用多尺度 DTW 方法，對不同時間尺度上的樣態進行分析，並在多尺度上決定閾值。這可以提高對不同頻率變化的敏感性。

5. 自適應閾值設置

- 基於歷史數據的自適應閾值: 根據歷史數據動態調整閾值。對每個新來的樣本，根據其與正常樣態的匹配結果，不斷更新閾值。
- 滑動窗口技術: 使用滑動窗口技術來動態更新正常樣態和閾值。隨著新數據的到來，不斷更新樣態並重新計算閾值。

6. 結合多種指標

- 多指標綜合判斷: 除了 DTW 距離之外，可以引入其他的時間序列相似度指標，如歐氏距離、馬氏距離等，並結合這些指標進行判斷。

[具體建議]

- 增強模擬次數: 增加蒙地卡羅模擬的次數，並嘗試不同的噪音模型。
- 監督學習: 如果有標註數據，考慮訓練監督式學習模型來自動調整閾值。
- 自適應方法: 使用自適應閾值設置，根據歷史數據動態調整。
- 多尺度 DTW: 引入多尺度 DTW，對不同時間尺度上的數據進行分析。

通過綜合這些方法，應該能夠更好地設置 DTW 閾值，從而減少誤報和漏報的情況。

當前應用中使用動態時間規整 (DTW) 來進行樣態比對時，多尺度DTW和自適應閾值設置是兩個有效的技術來提高準確性和魯棒性。以下詳細介紹這兩個技術的原理概念，並提供Python實作示例。

多尺度DTW (Multi-Scale Dynamic Time Warping)

[原理概念]

- 多尺度DTW是通過在不同的時間尺度上對序列進行分析來提高DTW匹配效果的一種方法。這個方法的核心思想是對序列進行多層次的細分，每個層次上應用DTW，從而更好地捕捉不同時間尺度上的變化。
- 尺度變換：將原始序列進行降頻 (down-sampling) 處理，生成多個尺度的序列。
- 多尺度匹配：對不同尺度的序列進行DTW匹配，得到不同尺度上的DTW距離。
- 綜合評估：綜合不同尺度上的匹配結果，給出最終的相似度評估。

```
import numpy as np
import scipy.signal
from fastdtw import fastdtw
from scipy.spatial.distance import euclidean

def downsample_sequence(sequence, factor):
    return scipy.signal.resample(sequence, len(sequence) // factor)

def multi_scale_dtw(template, sequence, max_scale=3):
    distances = []
    for scale in range(1, max_scale + 1):
        downsampled_template = downsample_sequence(template, scale)
        downsampled_sequence = downsample_sequence(sequence, scale)
        distance, _ = fastdtw(downsampled_template, downsampled_sequence,
                               dist=euclidean)
        distances.append(distance)
    return np.mean(distances)

# 示例用法
template = np.sin(np.linspace(0, 2 * np.pi, 100))
sequence = np.sin(np.linspace(0, 2 * np.pi, 60))

distance = multi_scale_dtw(template, sequence)
print(f"Multi-Scale DTW Distance: {distance}")
```

自適應閾值設置

[原理概念]

- 自適應閾值設置是一種根據歷史數據和當前數據動態調整閾值的方法。這樣的方法可以更好地適應數據的變化，減少固定閾值所帶來的誤報和漏報問題。
- 歷史數據分析：收集一段時間內的歷史數據，計算這些數據的DTW距離分佈。
- 閾值調整：根據歷史數據的統計特性 (如均值、標準差) 動態調整閾值。
- 實時更新：隨著新的數據到來，不斷更新歷史數據和重新計算閾值。

```
import numpy as np
from fastdtw import fastdtw
```

```

from scipy.spatial.distance import euclidean

class AdaptiveThresholdDTW:
    def __init__(self, initial_data, threshold_factor=1.5):
        self.history_distances = []
        self.threshold_factor = threshold_factor
        self.update_threshold(initial_data)

    def update_threshold(self, new_data):
        self.history_distances.append(new_data)
        self.mean_distance = np.mean(self.history_distances)
        self.std_distance = np.std(self.history_distances)
        self.threshold = self.mean_distance + self.threshold_factor * self.std_distance

    def is_normal(self, template, sequence):
        distance, _ = fastdtw(template, sequence, dist=euclidean)
        self.update_threshold(distance)
        return distance <= self.threshold

# 示例用法
template = np.sin(np.linspace(0, 2 * np.pi, 100))
initial_sequences = [np.sin(np.linspace(0, 2 * np.pi, 60)) + 0.1*np.random.randn(60) for _
in range(10)]

# 初始化自適應閾值DTW
adaptive_dtw = AdaptiveThresholdDTW([fastdtw(template, seq, dist=euclidean)[0] for seq
in initial_sequences])

# 檢查新的序列是否正常
new_sequence = np.sin(np.linspace(0, 2 * np.pi, 60)) + 0.1*np.random.randn(60)
print(f"Is new sequence normal? {adaptive_dtw.is_normal(template, new_sequence)}")

```

[詳細說明]

- 多尺度DTW

- 使用不同尺度的序列來進行DTW匹配，這樣可以捕捉到不同尺度上的模式。
- 具體實現中，我們對原始序列進行降頻處理，然後計算各尺度上的DTW距離，最終取平均值作為綜合距離。

- 自適應閾值設置：

- 通過對歷史數據計算DTW距離的均值和標準差，動態調整閾值。
- 每次新的匹配結果出現時，更新歷史數據並重新計算閾值，這樣可以適應數據的變化。
- 這些方法可以幫助你在樣態比對中更加精確地判斷序列的正常與否，減少誤報和漏報的情況。